# UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL INSTITUTO DE MATEMÁTICA E ESTATÍSTICA DEPARTAMENTO DE ESTATÍSTICA

# MAT02214 - Estatística Geral 1

### ÁREA 1

### **FORMULÁRIO**

### Tabela de Frequências

- Frequências absolutas e relativas: seja  $F_j$  a frequência absoluta do valor/classe j e n o total de elementos do conjunto de dados. A frequência relativa é dada por  $f_j = F_j/n$ .
- Número de classes (k):  $k = \sqrt{n}$  (regra empírica);  $k = 1 + 3,32 \log(n)$ , em que k é número de classes e n o número de observações. Ainda,  $i = a_t/k$ , em que i é a amplitude do intervalo,  $a_t = x_{(n)} x_{(1)}$  é a amplitude total, e  $x_{(1)}, x_{(n)}$  são os extremos inferior e superior do conjunto de dados.

#### Gráficos

• **Histograma:** a densidade de frequência é dada pela razão entre a frequência relativa da classe e a base (comprimento do intervalo) da classe.

#### Medidas Descritivas

Medidas de localização

- A média amostral (aritmética simples) é dada por  $\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \dots + x_n}{n}$ .
- Suponha que para os dados  $x_1, x_2, \ldots, x_n$  possuem os seguintes pesos  $p_1, p_2, \ldots, p_n$ , então **a média** aritmética ponderada é dada por  $\bar{x}_p = \frac{\sum_{i=1}^n x_i p_i}{\sum_{i=1}^n p_i}$ .
  - A média aritmética para dados **agrupados por intervalo de classe** é dada por  $\bar{x} = \frac{\sum_{j} c_{j} F_{j}}{n}$  em que,  $c_{j}$  é o ponto médio do intervalo de classe.
- A posição da mediana é dada por  $p = \frac{n+1}{2}$ . A **mediana** é dada por  $Md = x_{(p)}$ , quando n é par, e  $Md = [x_{(p_1)} + x_{(p_1)}]/2$ , quando n é impar. As posições dos **quartis** são dadas por  $p_1 = \frac{n+1}{4}$ ;  $p_2 = \frac{2(n+1)}{4}$ ;  $p_3 = \frac{3(n+1)}{4}$ , se n é impar, e  $p_1 = \frac{n+2}{4}$ ;  $p_2 = \frac{2n+2}{4}$ ;  $p_3 = \frac{3n+2}{4}$ . Os quartis são dados por  $Q_i = x_{(p_i)}$ . Se  $p_i$  não for um número inteiro, então  $Q_i = (x_{(\lceil p_i \rceil)} + x_{(\lfloor p_i \rfloor)})/2$ , em que  $\lceil p_i \rceil, \lfloor p_i \rfloor$  são o menor e o maior inteiro de  $p_i$ .

Medidas de variação ou dispersão

- A amplitude total é  $a_t = x_{(n)} x_{(1)}$ , em que  $x_{(1)}, x_{(n)}$  são os extremos inferior e superior do conjunto de dados.
- A variância amostral é dada por  $s^2=\frac{\sum_{i=1}^n(x_i-\bar{x})^2}{n-1}=\frac{\sum_{i=1}^nx_i^2-n\bar{x}^2}{n-1}.$ 
  - A variância amostral para dados **agrupados por intervalo de classe** é dada por  $s^2 = \frac{\sum_j F_j (c_j \bar{x})^2}{n-1}$  em que,  $c_j$  é o ponto médio do intervalo de classe.
- O desvio padrão amostral é igual a raiz quadrada da variância amostral:  $s=\sqrt{s^2}$ .
- O coeficiente de varição é  $CV = s/\bar{x}$ .

# Medidas de formato

- O coeficiente de assimetria é  $a_3 = m_3/(m_2\sqrt{m_2})$ , em que  $m_2 = \sum_{i=1}^n (x_i \bar{x})^2/n$  e  $m_3 = \sum_{i=1}^n (x_i \bar{x})^3/n$ .
- O coeficiente de curtose é  $a_4 = m_4/(m_2)^2$ , em que  $m_2 = \sum_{i=1}^n (x_i \bar{x})^2/n$  e  $m_4 = \sum_{i=1}^n (x_i \bar{x})^4/n$ .

#### Medidas de associação

- A covariância amostral entre X e Y é dado por  $cov(X,Y) = \frac{s_{xy}}{n}$ , em que  $s_{xy} = \sum_i (x_i \overline{x})(y_i \overline{y}) = \sum_i x_i y_i [(\sum_i x_i)(\sum_i y_i)]/n$ .
- O coeficiente de correlação linear amostral entre X e Y é dado por  $r = corr(X, Y) = \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}}$ , em que

$$- s_{xx} = \sum_{i} (x_i - \overline{x})^2 = \sum_{i} x_i^2 - (\sum_{i} x_i)^2 / n,$$

$$- s_{yy} = \sum_{i} (y_i - \overline{y})^2 = \sum_{i} y_i^2 - (\sum_{i} y_i)^2 / n \text{ e}$$

$$- s_{xy} = \sum_{i} (x_i - \overline{x})(y_i - \overline{y}) = \sum_{i} x_i y_i - [(\sum_{i} x_i)(\sum_{i} y_i)] / n;$$

ou

$$r = corr(X, Y) = \frac{cov(X, Y)}{\sqrt{\frac{S_{XX}}{n} \frac{S_{YY}}{n}}}$$